

UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA



**Curso:
Business Analytics**

**Inca Tenorio, Harold
Requena Falero, Diego
Salazar Delgado, Julio**

Lima, 3 de mayo de 2026

1. Problema de Negocio

"Una distribuidora musical latinoamericana debe decidir qué géneros, artistas y características de audio priorizar en su estrategia de entrada al mercado peruano, basándose en los patrones reales de consumo local y en la brecha entre lo que el oyente peruano declara preferir y lo que realmente escucha."

El cliente es una distribuidora musical que necesita saber, con base en datos reales de comportamiento:

- Qué géneros tienen momentum real en Perú durante los últimos 21 meses.
- Qué perfil sonoro diferencia al oyente peruano del resto de LATAM y del promedio global.
- Qué artistas locales muestran potencial de crecimiento antes de que su valor de mercado aumente.

La propuesta combina tres fuentes de datos: un dataset estático de 114,000 canciones con audio features, un dataset dinámico de rankings diarios de Spotify en 73 países, y una encuesta propia aplicada en el campus UTEC para capturar la perspectiva declarada del oyente peruano joven.

2. Datasets Utilizados

2.1 Dataset 1 - Spotify Tracks Dataset (audio features)

Dataset base que provee las características sonoras de las canciones. Fuente: Kaggle (Maharshi Pandya).

Característica	Valor
Total de filas	114,000 canciones
Columnas	21 (audio features + metadatos)
Géneros únicos	114 géneros (latin, reggaeton, salsa, pop, hip-hop...)
Valores nulos	Solo 1 fila con artista vacío - dataset limpio
Rango popularity	0 a 100 (media: 33.2)
Dimensión temporal	Ninguna - foto fija sin fechas

Variables clave del Dataset 1:

Variable	Tipo	Descripción
track_genre	Categorico	114 géneros etiquetados - variable ausente en el Dataset 2

Variable	Tipo	Descripción
danceability	Numérico 0–1	Aptitud para bailar. Media global: 0.676 Media Perú: 0.736 (+8.9%)
energy	Numérico 0–1	Intensidad y actividad percibida. Media global: 0.649 Media Perú: 0.681
valence	Numérico 0–1	Positividad musical. Media global: 0.546 Media Perú: 0.601 (+10.0%)
acousticness	Numérico 0–1	Nivel de sonido acústico. Media global: 0.275 Media Perú: 0.243 (-11.6%)
speechiness	Numérico 0–1	Presencia de palabras habladas. Identifica géneros como rap y reggaetón
instrumentalness	Numérico 0–1	Probabilidad de ausencia de vocals. Media global: 0.156
tempo	Numérico BPM	Velocidad de la canción. Media global: 122 BPM Media Perú: 117 BPM (-4.5%)
popularity	Entero 0–100	Popularidad calculada por Spotify. Media: 33.2. Rango: 0–100
explicit	Booleano	Indica contenido explícito. 8.6% del dataset (9,747 canciones)
track_id	String	Identificador Spotify - permite cruce con Dataset 2 (efectividad: 9.3%)

2.2 Dataset 2 - Universal Top Spotify Songs (rankings globales diarios)

Dataset dinámico que provee el comportamiento real de consumo por país. Fuente: Kaggle (asaniczka), actualización diaria.


Característica	Valor
Total de filas	2,110,316 registros diarios
Países cubiertos	72 países + ranking global (28,908 filas sin país)
Registros Perú (PE)	29,056 registros - 21 meses (oct 2023 – jun 2025)
Columna de género	NO existe en este dataset
Top artistas PE	Bad Bunny, KAROL G, Feid - La Única Tropical es el único artista peruano en el top

Variable	Tipo	Descripción
country	Código ISO	País del ranking. Perú = 'PE'. 28,908 filas sin país = ranking global

Variable	Tipo	Descripción
daily_rank	Entero 1–50	Posición en el ranking diario por país
daily_movement	Entero	Variación de posición respecto al día anterior (positivo = sube)
weekly_movement	Entero	Variación de posición respecto a la semana anterior
snapshot_date	Fecha	Fecha del registro - permite análisis de series de tiempo (21 meses)
spotify_id	String	ID Spotify - llave de cruce con Dataset 1 (9.3% de match en PE)
Audio features	Numéricos	danceability, energy, valence, acousticness, tempo, speechiness, instrumentalness, liveness

2.3 Limitación crítica: brecha en el cruce entre datasets

Solo el 9.3% de las canciones del Top 50 Perú (2,698 de 29,056 registros) tienen género identificable mediante el cruce por track_id entre ambos datasets. El 90.7% son canciones más recientes que el Dataset 1 de referencia y carecen de etiqueta de género. Esta limitación convierte a la encuesta propia en la fuente primaria de información de géneros del mercado peruano.




3. Estrategia de Enriquecimiento de Datos

Dado que ninguno de los dos datasets públicos responde directamente a las preguntas de negocio sobre preferencias declaradas del oyente peruano, el equipo diseñó y aplicó una encuesta propia en el campus UTEC para enriquecer el análisis con datos de primera mano.

3.1 Encuesta

La encuesta fue aplicada en campus UTEC como fuente de enriquecimiento. Con 21 respuestas al momento del EDA, constituye una muestra indicativa. Los hallazgos cualitativos son sólidos, pero los porcentajes se confirmarán al alcanzar 60 respuestas para el PC2.

Perfil de los encuestados: la muestra es joven (20–25 años, concentrada en 20–24 años) y mayoritariamente oyentes intensivos. 14 de 21 encuestados escuchan más de 4 horas de música al día, lo que la hace representativa del usuario activo de Spotify.



3.2 Variables nuevas que aporta la encuesta

La encuesta captura información imposible de obtener a partir de los datasets públicos:

Variable nueva	Por qué no está en los datasets y qué agrega
Géneros preferidos declarados	El Dataset 2 (rankings Perú) no tiene columna de género. La encuesta es la única fuente de esta información para el mercado peruano.
Perfil de audio buscado	Los datasets tienen los audio features de las canciones, pero no saben por qué el oyente las elige. La encuesta conecta la preferencia declarada con los números.
Conocimiento de artistas locales	Permite validar si los artistas peruanos que dominan el ranking (ej. La Única Tropical) son reconocidos conscientemente por los oyentes.
% música latina declarado	Variable para calcular la brecha entre lo que el oyente cree que escucha y lo que realmente domina su ranking. Esta pregunta es imposible de responder sin la encuesta.
Plataforma principal de escucha	Detecta sesgo de selección: si el oyente peruano usa principalmente YouTube o TikTok, los datos de Spotify no son representativos del 100% del consumo.

4. Preguntas Analíticas

El proyecto está estructurado alrededor de cuatro preguntas analíticas (PA) que responden directamente al problema de negocio:

PA	Pregunta
PA1	¿Qué géneros crecieron en el Top 50 Perú los últimos 21 meses y cómo se comparan con LATAM?
PA2	¿Qué características de audio diferencian las canciones populares en Perú del promedio global, y coincide con lo que el oyente dice preferir?
PA3	¿Qué artistas peruanos o emergentes muestran crecimiento consistente en el ranking?
PA4	¿Existe una brecha entre lo que el oyente peruano declara escuchar y lo que realmente escucha, y qué implica para la estrategia?

5. KPIs Propuestos e Hipótesis

Cada pregunta analítica fue traducida en hipótesis de negocio verificables. Para cada hipótesis se definió un KPI como instrumento de medición que permitirá aceptarla o rechazarla al concluir el análisis.


PA	Hipótesis	KPI de validación
PA1 Géneros	H1.1 Reggaetón, latin y cumbia han aumentado su presencia en el Top 10 PE a un ritmo mayor que en el resto de LATAM.	% de semanas en que estos géneros ocupan el Top 10 PE vs. hace 12 meses.
PA1	H1.2 El mercado peruano tiene mayor presencia de música tropical (cumbia, salsa) que Colombia o México.	Diferencia en pp de presencia por género entre Top 50 PE y promedio de AR, CO, MX.
PA2 Audio	H2.1 El Top 50 PE tiene mayor danceability y valence, y menor acousticness que el promedio global.	Media de danceability, energy y valence Top 50 PE vs. media global.
PA2	H2.2 Lo que el oyente declara buscar en una canción coincide con el perfil sonoro que domina el Top 50 PE.	% de encuestados cuya preferencia declarada (P5) coincide con el audio feature dominante en Top PE.
PA3 Artistas	H3.1 Existen al menos 3 artistas peruanos con presencia consistente y creciente en el Top 50 PE durante 21 meses.	N° de artistas peruanos con weekly_movement positivo en ≥10 semanas consecutivas.
PA4 Brecha	H4.1 El % real de música latina en el Top 50 PE supera al % que el oyente declara escuchar.	Diferencia en pp entre % música latina declarado (P10) y % real artistas LATAM en Top 50 PE.

PA4	H4.2 Los datos de Spotify no representan el 100% del consumo musical peruano, lo que limita el alcance de las recomendaciones.	% de encuestados que no usa Spotify como plataforma principal.
------------	--	--

6. EDA Inicial - Análisis Exploratorio de Datos

6.1 Top artistas en Perú - 21 meses de historia

Los artistas con mayor número de apariciones en el Top 50 diario de Perú revelan que el mercado está dominado por artistas internacionales latinoamericanos. Bad Bunny, KAROL G y Feid lideran con más de 1,200 apariciones cada uno. La Única Tropical es el único artista peruano en el top, con aproximadamente 950 apariciones, posicionándose en el 4º lugar general.




6.2 Perfil sonoro del oyente peruano vs. promedio global

El hallazgo más importante del EDA: el oyente peruano tiene un perfil sonoro propio y estadísticamente diferente al promedio mundial en todas las dimensiones clave. Las canciones que consumen son más bailables, más alegres y menos acústicas que el promedio global.


Audio Feature	Media Global	Media Perú	Diferencia	Interpretación
danceability	0.676	0.736	+8.9%	Más bailable
energy	0.649	0.681	+5.0%	Más energético

Audio Feature	Media Global	Media Perú	Diferencia	Interpretación
valence	0.546	0.601	+10.0%	Más alegre
acousticness	0.275	0.243	-11.6%	Menos acústico
tempo	122.1 BPM	116.6 BPM	-4.5%	Más pausado



6.3 Evolución temporal del Top 50 Perú - 21 meses

La rotación mensual de canciones únicas en el Top 50 revela la apertura del mercado a nuevas canciones. El rango oscila entre 60 y 87 canciones únicas por mes, con variación cíclica que sugiere estacionalidad en los patrones de consumo. Esta evolución es la base para el modelo de series de tiempo planificado para la Fase 2.



6.4 Calidad de datos, nulos y outliers

Dataset	Columna	Nulos	Decisión de limpieza
dataset.csv	artists	1 fila	Eliminar - irrelevante (0.001%)
universal_top...	country	28,908	Conservar como grupo 'GLOBAL' para comparación
universal_top...	Audio features	<0.05%	Imputar con mediana del país correspondiente

Outliers detectados con método IQR: canciones con instrumentalness >0.8 (música clásica), speechiness >0.4 (rap intenso) y tempo >200 BPM. No son errores - representan géneros legítimos y se mantienen en el dataset. Para el modelado se aplicarán transformaciones logarítmicas si el modelo es sensible a valores extremos.

6.5 Correlaciones iniciales


Par de variables	Correlación	Interpretación de negocio
energy ↔ loudness	+0.76	Fuerte positiva: canciones energéticas son más ruidosas - coherente con reggaetón.
energy ↔ acousticness	-0.73	Fuerte negativa: extremos opuestos del espectro sonoro.
valence ↔ danceability	+0.45	Moderada positiva: canciones alegres tienden a ser más bailables - reggaetón y cumbia son el ejemplo.
danceability ↔ daily_rank	-0.18	Negativa débil: canciones más bailables tienen mejor posición en el ranking peruano. Variable predictora clave para la regresión.
popularity ↔ daily_rank	-0.22	Correlación baja: la popularidad global no predice bien el ranking local - hay factores locales que Spotify no captura.

6.6 EDA del enriquecimiento - Encuesta propia

6.6.1 Géneros preferidos declarados


El reggaetón/urbano latino lidera las preferencias declaradas (13 menciones), seguido de pop en inglés (12), hip-hop/trap/R&B y salsa/cumbia (11 cada uno), y pop en español (9). Agrupando por origen, la música LATAM representa el 42% de las menciones totales y el pop en español el 13%, sumando un 55% de contenido en español - lo que supera la música

internacional (44.9%).




6.6.2 Tendencia de consumo de música en español

La mayoría de encuestados mantiene (13/21) o aumenta su consumo de música en español. Solo 2 de 21 escuchan menos que antes. Esto señala que el mercado peruano joven no está migrando hacia el inglés, sino consolidando su consumo de música en español.




6.6.3 Perfil sonoro declarado

El oyente peruano busca principalmente energía (10 menciones) y buen ritmo (7 menciones) en las canciones que elige. Esto coincide exactamente con el perfil sonoro que domina el Top Perú (energy=0.681, danceability=0.736), confirmando consistencia entre preferencia declarada y consumo real. En cuanto al momento de escucha, el 67% escucha música todo el día por igual.



6.6.4 Artistas peruanos: reconocimiento vs. presencia real


La mayoría de encuestados casi nunca escucha artistas peruanos activos (9/21), y 3 no conocen ninguno. Los más mencionados espontáneamente son Grupo 5 (3 menciones), La Única Tropical (2) y Agua Marina (2). Sin embargo, en los datos reales, La Única Tropical tiene 3,269 días de presencia en el Top 50 - es la más escuchada pero la menos reconocida conscientemente.




6.6.5 Cruces encuesta x datasets - Brecha declarado vs. real

El hallazgo central del proyecto: sí existe una brecha entre lo que el oyente peruano cree consumir y lo que realmente escucha. Declara un 40.9% de música latina, pero en realidad el 46.9% de su Top 50 es de artistas latinoamericanos - una brecha de +6 puntos porcentuales. La dirección de la hipótesis queda confirmada.

Una interpretación plausible: géneros como cumbia moderna o reggaetón ya no son identificados como 'música latina' por el oyente, sino como música mainstream. Esto representa una oportunidad para introducir nuevos artistas latinos sin resistencia de mercado.



VIZ CRUCE 2 — PA2: ¿Lo que el oyente busca está en el Top Perú?
Verde = feature alto en Top PE | Amarillo = medio | Rojo = bajo



7. Plan de Trabajo - Fase 2 (Semanas 7 a 14)

La Fase 2 tiene como objetivo validar las hipótesis pendientes mediante modelos estadísticos y predictivos, y sintetizar todos los hallazgos en un dashboard ejecutivo para la distribuidora.

7.1 Tareas, objetivos y metodologías

Sem.	Modelo / Tarea	Aplicación concreta	Hipótesis que valida
7	Regresión lineal	popularity ~ danceability + energy + valence en Top PE. Interpretar coeficientes.	H2.1 — ¿qué audio features predicen la popularidad en Perú?
8	Regresión logística	Predecir si una canción llega al Top 10 (sí/no) con las mismas 3 variables. Evaluar accuracy.	H2.2 — ¿qué perfil sonoro maximiza la probabilidad de Top 10 en Perú?

9	Series de tiempo	Evolución mensual del rank promedio de top 3 artistas en PE. Visualización + tendencia.	H1.1 y H1.2 — ¿qué géneros crecen? ¿Cómo se compara PE con LATAM?
10	Forecasting simple	Proyección de próximos 2 meses con media móvil por artista. Sin ARIMA.	H3.1 — ¿qué artistas tienen trayectoria ascendente?
11	Clustering K-means	3 clusters sobre danceability + energy + valence en Top PE. Nombrar cada cluster con criterio de negocio.	H2.1 — ¿qué segmentos sonoros existen en el mercado peruano?
12	Validar clusters + encuesta	Cruzar clusters con preferencias de encuesta. ¿En qué cluster están las canciones preferidas?	H2.2 — ¿en qué segmento sonoro está el oyente joven de UTEC?
13	Dashboard Power BI	4 visualizaciones clave con narrativa: problema → datos → insight → recomendación.	Comunicar todos los hallazgos al cliente en lenguaje ejecutivo.
14 (PC2)	Sustentación final	Presentación ejecutiva + notebook final + informe escrito con 60 respuestas de encuesta.	Confirmar magnitud H4.1 y resultado H4.2 con muestra completa.

7.2 Objetivos de la Fase 2

Validar las hipótesis pendientes H1.1, H1.2 y H3.1 con modelos de series de tiempo y forecasting.

Confirmar la magnitud de la brecha H4.1 con la muestra ampliada de 60 respuestas. Verificar si H4.2 supera el umbral del 30% con la muestra completa y declarar la limitación si corresponde.

Construir modelos de regresión lineal y logística para identificar los audio features que mejor predicen popularidad en el mercado peruano (H2.1 y H2.2).

Segmentar el mercado peruano en clusters sonoros y cruzarlos con las preferencias declaradas en la encuesta.